

Språk och Datorer (729G49)

Språkteknologi 4: Kollokationer

20/4/2026



Innehåll

- Repetition: Lingvistiskt uppmärkt text
- Kollokationer
- Idiom och fasta fraser
- n-grammar
- Pointwise Mutual Information (PMI)

Repetition:
Lingvistiskt uppmärkt text

1	Genom	genom	PP	3	AA
2	skattereformen	skattereform	NN	1	PA
3	införs	införa	VB	0	ROOT
4	individuell	individuell	JJ	5	AT
5	beskattning	beskattning	NN	3	SS
6	(	(	PAD	5	IR
7	särbeskattning	särbeskattning	NN	5	AN
8	)	)	PAD	5	JR
9	av	av	PP	5	ET
10	arbetsinkomster	arbetsinkomst	NN	9	PA
11	.	.	MAD	3	IP

Lingvistiska Annotationer

- Graford *skattereformen*
- Lemma *skattereform*
- Ordklass NN (substantiv)
- Huvudord Ord nummer 3 i meningen (*införs*)
- Grammatisk funktion SS (subjekt)
- Morfologiska egenskaper utrum, singular, definit, nominativ
- Betydelse skattereform..nn.1

1	Genom	genom	PP	3	AA
2	skattereformen	skattereform	NN	1	PA
3	införs	införa	VB	0	ROOT
4	individuell	individuell	JJ	5	AT
5	beskattning	beskattning	NN	3	SS
6	(	(	PAD	5	IR
7	särbeskattning	särbeskattning	NN	5	AN
8	)	)	PAD	5	JR
9	av	av	PP	5	ET
10	arbetsinkomster	arbetsinkomst	NN	9	PA
11	.	.	MAD	3	IP

Kollokationen

Kollokationer

- "As mature speakers of a language, we all know which words tend to occur with other words." (Yule, sid. 139)
- Ofta kan man förutsäga vilket ord kommer näst.
 - Varför?

Kollokationer

- En kollokation är en fast fras—en sekvens av två eller fler ord som ofta förekommer tillsammans
 - sparka ____ ?
 - salt och ____?
- Andra termer: fasta fraser, fasta uttryck, lexikaliserade fraser, idiom, ...

Varför är Kollokationer Viktiga?

- Flyt i språket – modersmålstalare hämtar hela fraser ur minnet
- Språkteknologi – kollokationer hjälper system att förutsäga ord:
 - maskinöversättning
 - talgenerering
 - stavningskontroll
- Lexikografi och andraspråksinlärning

Föränderliga och Oföränderliga Kollokationer

- Vissa kollokationer är oföränderliga:

trots allt, ont i halsen,...

- Andra kan varieras mer eller mindre:

sparka boll, ren lögn, salt och peppar,...

Typen av Kollokationer

Typ	Exempel
adjektiv + substantiv	nästa vecka, ren lögn
substantiv + substantiv	års fängelse, hösten 2024
verb + substantiv	äga rum, fatta beslut
adverb + adjektiv	mycket bra, allvarligt skadad
verb + adverb	skärpa till, ska inte
verb + partikel	ställa upp, köra över
verb + preposition	berätta om, tro på

Som bekant uppfördes Eiffeltornet till världsutställningen Exposition Universelle i Paris 1889, vilken påpassligt öppnade portarna ett sekel jämt efter den franska revolutionen. Jag vet inte riktigt när det där med världsutställningar kom ur mode. Eller om det överhuvudtaget fortfarande finns. Har ni hört talas om någon på sista tiden? Men då, förr alltså, var världsutställningar rejäla kioskvältare. Ett slags OS i teknologiskt och arkitektoniskt skryt.

Semantisk Transparens

- Kollokationer varierar i hur “genomskinlig” betydelsen är
- **Transparenta:** betydelsen följer av orden.
 - ‘snabb bil’, ‘strömt vatten’
- **Halvtransparenta** – delvis figurativa
 - ‘sparka boll’, ‘fatta beslut’, ‘dra en slutsats’
- **Opaka** (idiom) – betydelsen kan inte direkt härledas från orden
 - ‘köpa grisen i säcken’, ‘slå två flugor i en smäll’

Kollokationer som Lexikala Enheter

Kunskap om kollokationer och de medföljande lexikala, morfologiska och syntaktiska restriktionerna är viktig för andraspråksinlärning.

- Lina och Per har ont i halsen – *Lina och Per har ont i sina halsar

En andraspråksinlärare måste vanligtvis lära sig fraserna som lexikala helheter, vilket ofta är mödosamt.

- allvarligt/svårt skadad – seriously injured, schwer verletzt

<https://sprakbruk.fi/artiklar/fast-fraser-i-svenskan/>

Fasta Fraser





- *borsta tänderna*
 - **putsa tänderna*
 - **tvätta tänderna* (förutom finlandssvenskan som följt av inflytande från finskans *pestä hampaansa*),
- tyska: *die Zähne putzen*, norska: *å pusse tennene*
- franska: *se brosser les dents*, engelska: *to brush your teeth*
- spanska: *lavarse los dientes* (eller *cepillarse los dientes*)
- ... <https://sprakbruk.fi/artiklar/fast-fraser-i-svenskan/>

Kollokationsrestriktioner

- Lexikala restriktioner – vilka ord får kombineras?
 - stark kaffe / *kraftig kaffe
 - hög feber / *stor feber
 - begravd i arbete / *täckt i arbete
- Syntaktiska restriktioner – kollokationens form kan vara låst
 - ont i halsen / *ont i sina halsar
 - på fri fot / *på fria fötter

Idiomer

Svenska:	köpa grisen i säcken
Finska:	ostaa sika säkissä
Engelska:	buy a pig in a poke
Franska:	acheter un chat en poche,
Tyska:	die Katze im Sack kaufen
Nederländska:	een kat in de zak kopen



<https://sprakbruk.fi/artiklar/fast-fraser-i-svenskan/>

Vad är ett Idiom?

- Ett fast uttryck där betydelsen inte följer av de enskilda orden
- Semantiskt opakt och syntaktiskt låst
- Kulturellt förankrat – ofta svårt att översätta

Positive (Minimal Pairs Setup) 	Negative (Minimal Pairs Setup) 
string · lengths 	string · lengths 
När man misstänker att något är fel, anar man ugglor i mossen.	När man misstänker att något är fel, anar man råttor i mossen.
När en strängare ordning ska införas så ska det bli andra...	När en strängare ordning ska införas så ska det bli andra...
När man blir utsatt för hämnd får man betalt för gammal ost.	När man blir utsatt för hämnd får man betalt för gammal kål.
När man blir kraftigt tillrättavisad får man sina...	När man blir kraftigt tillrättavisad får man sina...
När man når framgång utan ansträngning glider man fram på...	När man når framgång utan ansträngning glider man fram på...
Goddag yxskaft, det du säger har inget med saken att göra.	Goddag halmstrå, det du säger har inget med saken att göra.
När en sista detalj fulländar något så är den som grädde på...	När en sista detalj fulländar något så är den som grädde på...
När man fortsätter med något som man alltid har gjort utan...	När man fortsätter med något som man alltid har gjort utan...
När allt går helt smidigt och	När allt går helt smidigt och

<https://huggingface.co/datasets/liu-nlp/swedish-idioms>

Idiom vs. Kollokation

- Kollokation – statistisk/lexikal tendens
 - orden förekommer oftare tillsammans än väntat
 - exempel: '*stark kaffe*', '*fatta beslut*'
- Idiom – semantisk enhet
 - helhetsbetydelsen skiljer sig från delarna
 - en delmängd av kollokationer: de mest opaka
 - exempel: '*bita i det sura äpplet*', '*dra åt samma håll*'
- → Idiom är kollokationer, men inte tvärtom

Översätta Kollokationer

Svenska	Engelska
Avsluta en affär	close a deal
Be en bön	say a prayer
Betala räkningar	foot the bill
Fatta eld	catch fire
Göra ett prov	sit a test
Rasta hunden	walk the dog
Väcka känslor	stir up emotions

n-grammar

n-grammar

- Unigram: Sekvens av 1 token
- Bigram: Sekvens av 2 tokens
- Trigram: Sekvens av 3 tokens
- ...
- n-gram: Sekvens av n tokens

Exempel

Som bekant uppfördes Eiffeltornet till världsutställningen (...)


Unigram	Bigram	Trigram
Som	Som bekant	Som bekant uppfördes
bekant	bekant uppfördes	bekant uppfördes Eiffeltornet
uppfördes	uppfördes Eiffeltornet	uppfördes Eiffeltornet till
Eiffeltornet	Eiffeltornet till	Eiffeltornet till världsutställningen

Användning av n-gram


- Språkmodeller:
 - Förutsäga nästa ord givet föregående kontext
 - $P(w_n \mid w_1, \dots, w_{n-1}) \approx P(w_n \mid w_{n-1})$
- Tillämpningar av språkmodeller:
 - Maskinöversättning – välja troligaste översättning
 - Stavningskontroll och autokomplettering
 - Taligenkänning – skilja homofoner åt
 - Stora språkmodeller?

Ord- och Bigramsannolikheter,

Skattning av unigramsannolikheter



Skattning av bigramsannolikheter



🔍

Linköping University,Uppsala University,Umeå University

✕


?

1922 - 2022 ▾

English ▾

Case-Insensitive

Smoothing ▾



Pointwise Mutial Information (PMI)

Tärningskast

- Vi kastar en vanlig sexsidig tärning.
 - Vad är sannolikheten för händelsen "jämnt antal prickar"?
- Vi kastar tärningen två gånger.
 - Vad är sannolikheten för händelsen "jämnt antal prickar vid första kastet och jämnt antal prickar vid andra kastet"?

Oberoende Händelser

Två händelser A och B kallas **oberoende** om och endast om sannolikheten för att båda ska inträffa är produkten av deras enskilda sannolikheter, dvs. om

$$P(A \text{ och } B) = P(A) \cdot P(B)$$

$$PMI(x, y) = \log \frac{P(x, y)}{P(x)P(y)}$$

$P(x)$	sannolikheten för att ordet x förekommer i korpusen
$P(y)$	sannolikheten för att ordet y förekommer i korpusen
$P(xy)$	sannolikheten för att orden x och y samförekommer
$P(x) P(y)$	oberoende sannolikheten för att ordet x förekommer och att ordet y förekommer

$$PMI(x, y) = \log \frac{P(x, y)}{P(x)P(y)}$$

- Om x och y är oberoende gäller $P(xy) = P(x) P(y)$ och kvoten är lika med 1.
- Om sannolikheten för händelsen att de två orden samförekommer är högre än sannolikheten för "nollhypotesen" att de är oberoende är kvoten större än 1.
- Om sannolikheten för att orden samförekommer är mindre än sannolikheten för nollhypotesen är kvoten mindre än 1.

Problem med PMI

- Att bara välja ut de ordpar som har högst antalet förekomster leder till ointressanta kollokationer.
 - *en boll* är mycket vanligare än *sparka boll*
- Vi skulle vilja ha ett mått som fokuserar på sammanhang i vilket två ord samförekommer **oftare än väntat**.

Kollokationsextraktion i Praktiken

- Typiskt arbetsflöde
 1. tokenisera och lemmatisera korpusen
 2. räkna n-gram (oftast bigram eller trigram)
 3. beräkna associationsmått (t.ex. PMI)
 4. filtrera och rangordna kandidater
- Vanliga filter: minimifrekvens, ordklasskombinationer, stoppordlistor

PMI-värden i 50M bigrammar i Wikipedia

(bara bigrammar med >1000 förekomster)

<i>word 1</i>	<i>word 2</i>	<i>count word 1</i>	<i>count word 2</i>	count of co-occurrences	PMI
puerto	rico	1938	1311	1159	10.0349081703
hong	kong	2438	2694	2205	9.72831972408
los	angeles	3501	2808	2791	9.56067615065
carbon	dioxide	4265	1353	1032	9.09852946116
prize	laureate	5131	1676	1210	8.85870710982
san	francisco	5237	2477	1779	8.83305176711
nobel	prize	4098	5131	2498	8.68948811416
ice	hockey	5607	3002	1933	8.6555759741
star	trek	8264	1594	1489	8.63974676575
car	driver	5578	2749	1384	8.41470768304
it	the	283891	3293296	3347	-1.72037278119
are	of	234458	1761436	1019	-2.09254205335

[https://en.wikipedia.org/wiki/Pointwise mutual information](https://en.wikipedia.org/wiki/Pointwise_mutual_information)

PMI-värden i 50M bigrammar i Wikipedia

(bara bigrammar med >1000 förekomster)

<i>word 1</i>	<i>word 2</i>	<i>count word 1</i>	<i>count word 2</i>	count of co-occurrences	PMI
puerto	rico	1938	1311	1159	10.0349081703
hong	kong	2438	2694	2205	9.72831972408
los	angeles	3501	2808	2791	9.56067615065
carbon	dioxide	4265	1353	1032	9.09852946116
prize	laureate	5131	1676	1210	8.85870710982
san	francisco	5237	2477	1779	8.83305176711
nobel	prize	4098	5131	2498	8.68948811416
ice	hockey	5607	3002	1933	8.6555759741
star	trek	8264	1594	1489	8.63974676575
car	driver	5578	2749	1384	8.41470768304
it	the	283891	3293296	3347	-1.72037278119
are	of	234458	1761436	1019	-2.09254205335

[https://en.wikipedia.org/wiki/Pointwise mutual information](https://en.wikipedia.org/wiki/Pointwise_mutual_information)

Exkurs:
**Hur bra är stora språkmodeller
på idiomatiskt språk?**

Idiomaticitet och Språkmodeller

- Språkmodeller tränas på data som ofta är översatt från engelska.
 - Resultat: grammatiskt oftast korrekt men inte *idiomatiskt naturligt*.
- Exempel: Svenskt idiom vs. översättning från engelska:
 - ✓ ”slå två flugor i en smäll”
 - ✗ ”slå två flugor med ett slag” (från eng. ”with one blow”)

Preferences for Idiomatic Language are Acquired Slowly — and Forgotten Quickly: A Case Study on Swedish

Jenny Kunz

Department of Computer and Information Science

Linköping University

jenny.kunz@liu.se

Abstract

In this study, we investigate how language models develop preferences for *idiomatic* as compared to *linguistically acceptable* Swedish, both during pretraining and when adapting a model from English to Swedish. To do so, we train models on Swedish from scratch and by fine-tuning English-pretrained models, probing their preferences at various checkpoints using minimal pairs that differ in linguistic acceptability or idiomaticity. For linguistic acceptability, we adapt existing benchmarks into a minimal-pair format. To assess idiomaticity, we introduce two novel datasets: one contrasting conventionalized idioms with plausible variants, and another contrasting idiomatic Swedish with Translationese. Our findings suggest that idiomatic competence emerges more slowly than other linguistic abilities, including grammatical and lexical correctness. While longer training yields diminishing returns for most tasks, idiom-related performance continues to improve, particularly in the largest model tested (8B). However, instruction tuning on data machine-translated from English — the common approach for languages with little or no native instruction data — causes models to rapidly lose their preference for idiomatic language.

1 Introduction

Even grammatically correct text can vary in how idiomatic or natural it sounds. Native speakers often prefer certain words or constructions over others, even when both are linguistically acceptable. These preferences influence how fluent or native-like a text *feels*.

In translation studies, the tendency of trans-

1986). While initially observed in human translations, Translationese is now primarily discussed in relation to machine-translated text. We hypothesize that a similar phenomenon arises in language model outputs for non-English languages. Since English dominates LLM pretraining data, transfer effects — which are generally desirable! — can introduce anglicized patterns. Furthermore, parts of the training data in lower-resource languages may themselves be translations from English. This influence continues post-training, where steps such as instruction tuning are often performed using machine-translated datasets, as native data is rarely available (Muennighoff et al., 2023; Holmström and Doostmohammadi, 2023; Chen et al., 2024).


The idiomaticity of LLM outputs in non-English languages remains however understudied. This property is less straightforward to define or evaluate than grammaticality or factuality, as idiomatic preferences are more subjective and variable. Factors such as age, region, and exposure to English shape what speakers perceive as natural.

While previous work has examined Translationese in LLM-generated *translations* (Raunak et al., 2023; Li et al., 2025), to our knowledge, no existing research has investigated general idiomaticity preferences in LLMs. Consequently, there are no existing datasets for Swedish that address this issue explicitly. To address this gap, we introduce two Swedish datasets designed to probe LLMs’ idiomatic preferences: one contrasts conventionalized idioms with plausible alternatives; the other contrasts Translationese Swedish with idiomatic alternatives.

We use these datasets to track small (135M, 8B) LLMs’ preferences for idiomatic language during pretraining and continued pretraining. Our

Idiom i LLM:er (Kunz 2025)

- Träningsdynamik:
 - Idiomatisk kompetens utvecklas mycket långsammare än grammatik
 - Instruction fine-tuning med översatt data:
 - Idiomatiska preferenser försvinner snabbt vid finjustering
 - Grammatisk korrekthet påverkas däremot mycket mindre
- > Nativ data och idiomatisk evaluering behövs!



Translationese i Språkmodeller

När språkmodeller genererar svensk text:

- Är den idiomatisk eller liknar den *översättningssvenska*?
- Hur skiljer sig översättningssvenska egentligen från idiomatisk svenska?

<https://arxiv.org/pdf/2603.08450>

A Dataset for Probing Translationese Preferences in English-to-Swedish Translation

Jenny Kunz Anja Jarochenko Marcel Bollmann

Department of Computer and Information Science

Linköping University

jenny.kunz@liu.se anjja777@student.liu.se marcel.bollmann@liu.se

Abstract

Translations often carry traces of the source language, a phenomenon known as *translationese*. We introduce the first freely available English-to-Swedish dataset contrasting translationese sentences with idiomatic alternatives, designed to probe intrinsic preferences of language models. It includes error tags and descriptions of the problems in the original translations. In experiments evaluating smaller Swedish and multilingual LLMs with our dataset, we find that they often favor the translationese phrasing. Human alternatives are chosen more often when the English source sentence is omitted, indicating that exposure to the source biases models toward literal translations, although even without context models often prefer the translationese variant. Our dataset and findings provide a resource and benchmark for developing models that produce more natural, idiomatic output in non-English languages.

Keywords: Translationese, Idiomaticity, Machine Translation, Evaluation, Minimal Pair Probes

1. Introduction

Translations have long been known to carry traces of the source language and differ in style and features from texts originally written in the target language; a phenomenon commonly called *translationese* (Gellerstam, 1986). Research shows that translationese is particularly strong in machine translation, leading to simplified and less varied language marked by reduced lexical and morphological richness (Vanmassenhove et al., 2021). Such output is often easily distinguishable from original text (Koppel and Ordan, 2011; Li et al., 2025). Recent work suggests that LLMs produce less literal translations (Raunak et al., 2023). However, even though their outputs show increased lexical diversity compared to specialized machine translation systems, they can still be reliably distinguished from human-written text (Kong and Macken, 2025).

For many languages, it is common to use translated datasets especially for LLM evaluation (Nielsen, 2023; Bandarkar et al., 2024) and instruction tuning (Li et al., 2023; Dac Lai et al., 2023; Holmström and Doostmohammadi, 2023), as there is often no practical alternative. In addition, for low-resource languages, but to a lesser extent even for high-resource languages such as English, large portions of modern web-crawled corpora that constitute the training data of LLMs are translations (Thompson et al., 2024). It is therefore important to analyze this problem and assess its extent in

on translationese (Katourgi, 2022), which contains translations with translationese phrasing alongside idiomatic alternatives suggested by the author, they examine whether the model assigns higher probability to the translationese version or to the idiomatic alternative. Building on this work, we construct a dataset for probing translationese preferences. Our dataset is similar in its setup, but addresses several limitations of the previous dataset: it is fully open under a permissive license, includes the English source sentence with preceding context to also study preferences in a translation context, and provides annotations tagging the type of translationese, enabling more fine-grained analysis of model behavior. To our knowledge, this is the first freely available dataset explicitly contrasting translationese with idiomatic alternatives for Swedish.

We provide a detailed description of the dataset, including both qualitative and quantitative analyses of translationese examples in English-to-Swedish translations produced by a smaller specialized machine translation system. We also compare these to translations generated by a state-of-the-art LLM, highlighting that while it does not fully resolve any specific problem, it is much better at generating more idiomatic words and phrasings.

In experiments probing the intrinsic preferences of smaller multilingual LLMs with our dataset, findings show a strong bias toward the translationese phrasing. Notably, models favor the human alternative more often when omitting translation context in

Kunz, Jarochenko and Bollmann (2026)

Språkmodeller är ofta mer benägna att generera översättningssvenska än idiomatisk svenska:

- Sannolikheten av det maskinöversatta alternativet är ofta större.

english_source string · lengths	swedish_opus string · lengths	swedish_human string · lengths
 51↔67 13%	 38↔55 21.2%	 34↔50 23%
Let's go.	Låt oss gå.	Nu går vi
You've done nothing but hunt...	Du har bara jagat mig hela tiden.	Du har inte gjort annat än att jaga...
And for what?	Och för vad?	Men varför?
All you have to do is lower that...	Allt du behöver göra är att sänka...	Det enda du behöver göra är...
You will understand the...	Du kommer att förstå mysteriern...	Du kommer att förstå livets och...
I command you, condemn you in th...	Jag befäller dig att fördöma dig i...	Jag befäller dig, fördömer dig, i...

<https://huggingface.co/datasets/liu-nlp/translationese-opensubtitles>

L4

Tack för idag!